

ESS 배터리 수명 예측

EDA 기반 모델 설계 전략

MIT-Stanford 배터리 사이클링 데이터 (Severson et al., Nature Energy 2019) · Batch 1 + 2 + 3

진행 방식

1

입력 데이터 이해

Notion Features-Battery Index로 필드를 파악하고 Target Data = cycle_life로 정의 → 가설 기반으로 사용할 데이터 선정

2

데이터 정리 · 전처리

Target(cycle_life) 값이 정의에 맞는 지 점검, 측정 오류·결측 처리, 처리 건수와 영향 확인

3

EDA Q1-Q5

Notion 5개 질문을 배치별로 수행·비교. 질문마다 목적 → 수행 → 결과 → 시사점

4

Feature Engineering

EDA 결과로 정한 기준(S1-S5)을 학습 배치(B1)에만 적용해 변수 선별

5

모델 설계 전략

회귀/분류 선택, Target, 데이터 처리, 후보 모델과 검증 설계

구성 입력 데이터 (p.2-3) · 전처리 (p.4-5) · Q1 수명 분포 (p.6-7) · Q2 열화 곡선 (p.8-9) · Q3 $\Delta Q(V)$ (p.10-12) · Q4 충전 조건 (p.13-14) · Q5 상관관계 (p.15) · 종합 (p.16) · 모델 설계 전략 (p.17-19) · 결론 (p.20)

ISSUE

어떤 실험에서 나온 어떤 데이터이고, 그중 무엇을 왜 쓰는가?

실험 개요 (원논문 · 데이터로 확인)

- 상용 LFP/흑연 18650 셀, 공칭 용량 1.1Ah
- 0→80% SOC를 1단계 또는 2단계 고속 충전(충전방식별로 다름) → 이후 정전류·정전압 충전
- 방전 4C, 전압 2.0~3.6V, 챔버 약 30℃ (데이터의 I·V·T 범위로 확인)
- 용량이 80%(0.88Ah) 아래로 떨어질 때까지 반복 충방전

데이터 규모 · 구조

- .mat(HDF5) 3개 배치 + extra, 7.7GB · 139셀 · 116,722 사이클
- 셀 → 사이클 요약(셀 × 사이클 1행) → 사이클 내부 시계열(사이클당 약 1,000점)의 3단계
- 원논문 역할: B1 학습 · B2 1차 테스트 · B3 2차 테스트

가설 기반 데이터 정의

- **H1** 열화 초기 신호는 용량 총량보다 방전 곡선 형태(전압별 용량)에 먼저 나타난다 → Qdlin · Q2, Q3
- **H2** 충전 전류가 클수록 열화가 빠르다 → 충전방식 · Q4
- **H3** 저항 증가·발열이 열화를 반영한다 → IR, 온도 · Q5

단계	필드	의미 (Notion Features)	사용 여부 · 이유
셀	cycle_life	EOL(80% 용량)까지 총 사이클 수	Target Data (Y)
	policy_readable	충전방식. 4.8C(80%)-3.6C = 80%까지 4.8C, 이후 3.6C	✓ EDA: 충전 조건과 수명의 관계 확인 (H2, Q4)
	Vdlin	Qdlin의 전압 축 (2.0~3.5V, 1,000점)	ΔQ(V) 계산 축
	barcode, channel_id	셀 ID · 측정 채널	미사용 (이 파일에서 비어 있음)
사이클 요약 (summary)	QDischarge / QCharge	방전 / 충전 용량 (Ah)	✓ 열화 곡선(Q2), 초기 용량 피쳐
	IR	내부 저항 (Ω)	✓ 피쳐 후보 (H3)
	Tmax / Tavg / Tmin	사이클 내 최고 · 평균 · 최저 온도 (℃)	✓ 피쳐 후보 (H3)
	chargetime	충전 소요 시간 (분)	✓ 피쳐 후보 (H2)
	cycle	사이클 번호	정렬 · 초기 100 cycle 구간 지정
사이클 내부 시계열 (cycles[n])	Qdlin	전압 축으로 선형 보간한 방전 용량 → ΔQ(V)의 기반	✓ cycle 10 · 100 (H1, Q3)
	t, V, I, T	시간 · 전압 · 전류 · 온도 원시 시계열	미사용: 같은 정보가 summary·Qdlin에 이미 요약돼 있어서
	Qc, Qd	원시 충전 / 방전 용량 곡선	미사용: 셀끼리 비교하려면 전압 축이 맞춰진 Qdlin이 필요해서
	Tdlin, discharge_dQdV	보간 온도, 방전 dQ/dV 곡선	미사용 (DAY 2 확장 후보)

Notion Features의 discharge_time은 이 파일에 없음 · 수명 신호는 초기 100 cycle 구간에서 추출(DAY 1 Q3·Q5 범위), 열화 곡선 전체는 Q2에서 패턴 확인용

ISSUE Target Data = cycle_life — 무엇을, 왜 예측하는가?

Target Data = cycle_life · 정의와 선정 이유

- **Target Data = cycle_life**: 셀 용량이 처음의 80%(0.88Ah, EOL)로 떨어질 때까지 돈 총 사이클 수 (Notion Target 정의)
- ESS는 SOH 80% 이하에서 배터리를 교체하므로(Notion Battery Index), cycle_life가 곧 “언제 교체해야 하나”라는 운영 질문의 답이라 선정
- 예지 보전의 핵심 지표인 RUL(남은 수명 = EOL까지 남은 사이클)도 cycle_life에서 바로 나와, 하나의 값으로 교체 시점과 남은 수명을 함께 다룰 수 있어 선정
- 셀마다 값이 하나로 정해져 있고 분석 대상 119셀 모두 값이 있어 배치 간 비교가 가능

기대 효과 (Notion Battery Index)

- 초기 100 사이클만으로 교체 시점을 미리 계획할 수 있어 운영 비용 20~35% 절감
- 갑작스러운 수명 종료로 인한 설비 중단, 용량 부족으로 인한 피크 대응 실패와 계약 위약금 위험 감소
- 필요 이상으로 일찍 바꾸는 예방 교체를 줄여 셀 교체 비용(1MWh당 \$30,000~80,000, CAPEX의 30~40%) 절감
- 제조 직후 단수명 셀을 미리 걸러 팩 구성을 최적화하고, 열화 속도 예측으로 충방전 전략을 조정


분석 범위: Target과 함께 볼 신호는 무엇인가?

- **Target = cycle_life** (셀당 1개)
- **함께 볼 신호 = 초기 100 cycle의 측정값**: 사이클 요약(QD, QC, IR, 온도, 충전시간) + 방전 곡선 Qdlin(V)
- 초기 구간으로 한정된 이유: DAY 1 질문이 초기 사이클을 보도록 정의돼 있음 — Q3 “사이클 100번 – 사이클 10번”, Q5 “초기 사이클 피쳐”
- 도메인 정보(Notion 배터리 교체 비용 항목)에서 “초기 100사이클만으로 전체 수명 예측 가능”이라고 하니 100사이클로 예측 시도
- 열화 곡선 전체는 Q2에서 수명 패턴을 이해하는 데만 사용. 충전방식은 측정값이 아닌 실험 설계 조건이라 Q4에서 따로 확인

데이터 정리 · 점검 과정

- .mat(HDF5) 3개 배치 7.7GB → h5py로 필요한 필드(summary, cycle_life, 충전방식, Qdlin 150 cycle)만 읽어 셀별 캐시(약 90MB)
- 세 배치의 cycle 번호가 1부터인지(인덱스 j = cycle j+1) 확인
- Target(cycle_life)이 정의와 맞는지 점검: 마지막 용량이 0.88Ah에 닿았는지, 첫 0.88Ah 미만 사이클과 일치하는지 → EOL 도달 / EOL 미도달인데 값 있음 / 값 없음으로 분류
- 측정 오류 점검: cycle 1 더미, 용량 스파이크, IR 0 기록, 충전시간 튜브 (처리는 전처리 ①·②)
- extra 파일(varcharge 2셀)은 Target 값이 없어 제외 → 139셀 대상

ISSUE 기록된 수명 값이 있는데 왜 셀을 빼는가? — 값이 Target 정의에 맞는지 확인



EOL 미도달이란?

- EOL(수명 끝) = 용량이 처음의 80%인 **0.88Ah** 아래로 떨어지는 순간. 그때까지의 사이클 수가 Target(cycle_life)
- 그런데 일부 셀은 **배터리가 아직 살아 있는데 실험이 먼저 끝났고**, 측정을 멈춘 시점의 사이클 수가 cycle_life로 적혀 있음
- 예: B1c0은 1,189 cycle에서 측정 종료, 용량 아직 93% → 기록은 1,190이지만 진짜 수명은 그보다 김
- 마라톤 20km 지점 시간을 완주 기록으로 적어 둔 것과 같음




왜 뺐나

- 틀린 Target 값으로 학습하면 오래 사는 셀을 “짧게 산다”고 배워 예측이 아래로 치우침
- 넣으면 온도-수명 상관관계가 -0.48 로 강하게 나오지만, 천천히 충전해 가장 시원하고(46셀 중 1~4~7위) 가장 오래 사는 잘린 셀 5개(B1c0-4)가 끌어낸 값. Target 값이 확실한 36셀만 보면 -0.17
- 정상 셀 수명 상위 10개와 하위 10개의 평균 온도 차도 0.5°C (32.0 대 32.5)뿐 → 온도는 수명을 정하는 신호라기보다 충전 속도를 따라 움직인 결과
- 원문은 B1c0-4를 다른 파일에 이어 측정한 데이터로 수명을 복원했지만, Kaggle 파일엔 그 데이터가 없어 복원 불가
- 제외: B1 10셀(마지막 용량 0.91~1.04Ah) + B3 2셀(2,000 cycle 넘게 미도달)

“cycle_life에 숫자가 있다고 올바른 Target은 아니다 — 값이 정의(EOL 80% 도달)에 맞는지 확인해야 틀린 Target 값을 걸러낼 수 있다”

전처리 ② 전처리 과정: 처리 내용 · 규칙 · 건수

ISSUE 신뢰할 수 있는 학습 데이터 — 문제 발견 → 규칙 설정 → 처리 건수·영향 확인 순서로 진행



셀 선별 결과 — 총 139셀 중 20셀 제외 → 119셀 사용 · B1 46 → 36 (EOL 미도달 10) · B2 47 → 39 (Target 값 없음 8) · B3 46 → 44 (Target 값 없음 2) · extra 파일 2셀은 별도 제외

문제 (발견 경로)	처리 규칙	처리 건수 (B1 / B2 / B3)
EOL 미도달 · Target 값 없음 (마지막 QD 점검)	마지막 QD > 0.885Ah 또는 cycle_life NaN → 셀 제외	10 / 8 / 2 셀 제외
cycle 1 더미 (구조 점검)	QD = 0, Qdlin NaN인 cycle 1 제거	36 / 0 / 0 셀
QD 측정 오류 (Q2 열화 곡선)	① 0.5~1.3Ah 밖 ② rolling median(11)에서 $\pm 0.02\text{Ah}$ 이탈 → 앞뒤 값으로 보간	① 1 / 0 / 0 건 · ② 1 / 8 / 2 건
IR 0 기록 · 충전시간 텀	IR ≤ 0 → 결측, 시간 통계는 평균 대신 중앙값	IR 0 / 6 / 0 셀 · 충전시간 3 / 10 / 0 셀
ΔQ 의 사이클 선택 민감도	cycle 100-10 유지 (대안 4개와 비교)	—

① 셀 선별

배치별 사용 셀(초록)과 제외 셀. B1은 EOL 미도달 10셀(주황)을 빼 36셀, B2·B3는 Target 값 없음 8·2셀(회색)을 빼 39·44셀 → 총 119셀 사용

② 스파이크 보정 예시


B2c33의 용량이 cycle 75 부근에서 한 번만 0.925Ah로 떨어졌다가 바로 1.06Ah대로 돌아옴. 한 사이클에 14% 줄었다 회복하는 건 실제 열화가 아니라 측정 오류라, 앞뒤 11개 중앙값과 0.02Ah 이상 차이 나는 값(빨간 점)을 앞뒤 값으로 메움(파란선)

③ ΔQ 비교 사이클 확인

ΔQ 를 cycle 100-10 대신 99-9, 101-11, 100-20, 여러 사이클 중앙값으로 바꿔 계산해도 기준과 상관 0.98 이상, 수명과의 상관도 0.80~0.83으로 같아 100-10을 그대로 사용

Cycle Life 분포: 배치별 수명 분포와 이상치

ISSUE 수명(target) 분포 확인 — 배치마다 같은 분포인가?



1 목적 · 왜 봤나

타깃의 형태(범위·왜도)와 배치 간 차이를 알아야 타깃 변환, 외삽 필요성, 회귀/분류 선택을 정할 수 있다

2 무엇을 했나

- **[Histogram]** 배치별 히스토그램(100 cycle 간격)
+ 박스플롯·개별 셀
- **[장/단수명 비율]** >1,000 / <500 셀 수를 배치별 집계
- **[이상치·왜 짧은가]** IQR 1.5배 규칙으로 식별 → 해당 셀의 충전방식·셀 구조 추적

3 결과 · 해석

- 평균 B1 788 · B2 566 · B3 1,060 (392~1,935)
- 장수명 26%(31셀), 단수명 24%(28셀, **전부 B2**)
- 이상치: B2 9셀 **전부 newstructure**, B3 3셀(1,801~1,935)
- 최단 셀(B2 392~425)은 기존 구조 + 고속 프로파일. B1 최단 c20·c21(534·559)은 5.4C를 80%까지 유지




4 시사점 → 모델링

- 수명이 오른쪽으로 치우쳐 있어 로그 변환을 검토
- B2 39셀 중 30셀이 B1 최솟값(534)보다 짧아, 학습 범위 밖도 예측할 수 있는 **외삽 가능한 모델**이 필요
- 550 cycle로 나누면 B1이 35:10이라 분류는 어렵고 회귀가 적합

“ B2의 “이상치”는 측정 오류가 아니라 셀 구조가 다른 하위집단이다 — ESS 운영에서는 충전방식보다 입고 셀(로트) 선별이 수명 편차를 더 크게 만든다 ”

Q1 수명 분포: 로그 변환 전/후와 핵심 피쳐 분포

ISSUE 타깃이 치우쳐 있다면 어떻게 다룰 것인가? 피쳐도 배치마다 위치가 다른가?



변수	Batch	평균	표준편차	최소	중앙값	최대	왜도
cycle life	B1	788	149	534	773	1,074	0.29
	B2	566	222	392	472	1,186	1.57
	B3	1,060	314	541	1,006	1,935	1.21
log10 life	B1	2.89	0.08	2.73	2.89	3.03	-0.01
	B2	2.73	0.14	2.59	2.67	3.07	1.30
	B3	3.01	0.12	2.73	3.00	3.29	0.50
log Var ΔQ	B1	-3.79	0.23	-4.18	-3.79	-3.35	0.21
	B2	-3.60	0.39	-4.45	-3.49	-3.09	-0.91
	B3	-4.19	0.29	-5.10	-4.18	-3.45	-0.22

2 무엇을 했나

- 타깃 log10 변환 전/후 분포·왜도 비교
- 핵심 피쳐의 배치별 분포 비교 + B1 범위 밖 비율 + KS 검정

3 결과 · 해석


- 왜도 1.04 → 0.03 (전체). B2는 1.30 유지: 기존 구조·newstructure 두 집단 혼재
- log Var ΔQ: B2는 B1보다 오른쪽(단수명), B3는 왼쪽(장수명). B1 범위 밖 B2 44% · B3 48%, KS $p < 1e-5$

4 시사점 → 모델링

- 로그로 퍼면 대칭이 되므로 target은 log10(cycle_life)로 확정. B2는 두 집단이 섞여 있어 오차를 구조별로 나눠 봄
- 피쳐도 학습 범위 밖으로 나가므로 직선으로 외삽되는 모델을 우선하고, 스케일러는 B1에서만 fit

Q2 열화 곡선: 방전 용량의 감소 패턴

ISSUE 용량은 일정하게 줄어드는가, 어느 순간 가속되는가?



1 목적 · 왜 봤나

열화 패턴(선형/가속)을 알아야 “초기 100 cycle의 용량만으로 수명을 맞출 수 있는지”, 다른 신호가 필요한지 판단할 수 있다

2 무엇을 했나

- **[사이클별 Qd 추이]** 119셀 QD를 배치별로, 수명 색상으로 시각화 (스파이크 보정 후)
- **[일정 vs 가속]** cycle 2→100 용량 변화 부호 집계, 초기 기울기와 수명의 배치별 상관

3 결과 · 해석

- 모든 셀이 완만한 감소 → 급락하는 knee형
- 초기 100 cycle엔 용량이 오히려 증가: $QD(100) > QD(2)$
셀 B1 89% · B2 64% · B3 84%
- 초기 용량 1.05~1.12Ah로 수명과 무관하게 겹침
- 초기 기울기-수명 $\rho -0.21$ (배치별 +0.47 / -0.25 / +0.09)




4 시사점 → 모델링

- 초기 용량만으로는 셀이 구분되지 않아 곡선 형태를 보는 신호(ΔQ)가 필요
- 열화가 갑자기 빨라지므로 초기 기울기를 직선으로 늘려 수명을 추정할 수 없음
- 측정 스파이크가 있어 보정한 용량을 사용

“ 초기 100 cycle 동안 용량은 거의 그대로다 — 운영 중 용량만 모니터링해서는 교체 시점을 미리 알 수 없다 ”

Q2 Knee point: 급격한 열화의 시작점

ISSUE 급락 시작점(knee)은 수명과 어떤 관계이고, 100 cycle 시점에 보이는가?



1 목적 · 왜 봤나

가속이 시작되는 시점을 정량화해 “100 cycle 시점에 볼 수 있는 정보가 무엇인지” 확인한다

2 무엇을 했나

- **[Knee 탐색]** 셀마다 두 직선 piecewise 회귀, 오차 제곱합이 최소인 분기점(5 cycle 간격 탐색)
- **[열화 가속]** knee 전·후 기울기 비교
- knee 위치와 수명의 상관, knee/수명 비율 분포

3 결과 · 해석

- knee = 수명의 **77%** (59~87%), knee-수명 ρ 0.99 (배치별 0.94~0.98)
- knee 이후 열화 **10.4배** 빨라짐 (모든 셀 1.5배 초과)
- 가장 이른 knee도 245 cycle (최단 수명 셀 295)




4 시사점 → 모델링

- 수명 $\approx \text{knee} \div 0.77$ 이라 결국 knee가 언제 오는지를 맞히는 문제
- knee는 cycle 100에 아직 안 보이므로 피쳐로 쓰면 미래 정보를 쓰는 셈(누수)
- 그래서 cycle 100 안에 보이는 대리 신호(ΔQ)가 필요

“수명의 마지막 약 23% 구간에서 용량이 급락한다 — 교체 계획은 knee 이전에 세워야 하고, 그 근거가 될 조기 신호가 필요하다”

Q3 $\Delta Q(V)$ 의 의미: 방전 곡선에서 읽는 열화 신호

ISSUE 100 cycle 시점에 용량 총량은 비슷한데, 수명 차이를 어디서 알아볼 수 있는가?



① 방전 곡선

- 방전하면 전압이 3.5V → 2.0V로 떨어지는 동안 용량(Ah)이 빠져나옴. 이를 “전압 vs 나온 용량”으로 그린 것
- LFP 셀은 2.9~3.15V 평탄 구간에서 전압은 거의 그대로인데 용량 대부분이 나옴
- cycle 100 곡선(빨강 점선)이 cycle 10보다 살짝 왼쪽 → 같은 전압까지 나온 용량이 줄어듦 = 열화

② $\Delta Q(V) = Q(\text{cycle } 100) - Q(\text{cycle } 10)$

- 두 방전 곡선을 전압마다 뺀 값. 음수 = 그 전압까지 나온 용량이 100번째에 그만큼 줄었다는 뜻 (Qdlin은 이 뺄셈을 위해 1,000개 전압 지점에 맞춰 둔 곡선)
- 빨강(B1c20, 수명 534)은 골이 깊고(-0.063Ah), 파랑(B1c5, 수명 1,074)은 얕음(-0.025Ah)
- 용량 총량은 두 사이클이 비슷해도 전압별 차이는 이미 벌어져 있어, 100 cycle 시점에 단수명 셀을 알아볼 수 있음. 이 골이 얼마나 깊고 넓은지를 숫자 하나로 요약한 것이 핵심 피쳐 log Var ΔQ


③ 노이즈(지글거림)

- 평탄 구간에선 전압 0.01V 변화에 용량 약 0.026Ah가 나옴 → 전압 측정 오차 1mV가 용량 차이 약 0.003Ah로 부풀려짐
- 그래서 지글거림은 평탄 구간(3.0~3.15V)에만 나타남 — 배터리 변화가 아니라 측정 오차 (14셀: B1 10 · B2 2 · B3 2)
- 스무딩 전후 핵심 피쳐 차이 최대 0.06, B1 수명 상관 -0.826 → -0.825로 결과 영향 없음 → 원본 사용

“용량 총량은 비슷해도 전압별 차이는 이미 벌어져 있다 — 골의 깊이·넓이(log Var ΔQ)로 100 cycle 시점에 단수명 셀을 알아본다”

Q3 $\Delta Q(V)$ 곡선: 초기 사이클의 차이

ISSUE 용량 총량에서 안 보이던 차이가 방전 곡선의 “형태”에는 나타나는가?



1 목적 · 왜 봤나

Q2에서 초기 용량으로는 셀이 구분되지 않았다. 같은 용량이라도 전압 구간별 용량 분포(곡선 형태)가 변했는지 확인한다

2 무엇을 했나

- [cycle 100 – cycle 10] Qdlin(V) 차이를 2.0~3.5V 1,000포인트에서 계산
- [장/단수명 ΔQ 형태 비교] 119셀을 수명 색상으로 배치별 겹쳐 그림

3 결과 · 해석

- 모든 셀에서 2.7~3.1V 부근 음의 골(trough)
- 단수명(노랑) 골 $-0.04 \sim -0.09\text{Ah}$ 로 깊고, 장수명(보라·청록) $-0.02 \sim -0.03\text{Ah}$ 로 얕음
- B1·B2·B3 모두 색 순서 일치
- B3 장수명 일부는 3.1V 부근 양(+) 돌출·노이즈




4 시사점 → 모델링

- [통계값 피쳐 추출] 골의 깊이·퍼짐을 담도록 분산·최솟값·평균·왜도·첨도를 계산
- 양(+)으로 솟는 셀이 있어 절댓값 로그를 취할 때 부호가 사라지는 점에 주의

“ QD 총량은 같아도 곡선 모양은 이미 갈라져 있다 — 수명의 5~25% 시점(100 cycle)에 단수명 셀을 조기 선별할 근거 ”

Q3 $\Delta Q(V)$: 장/단수명을 구분하는 통계값 피쳐

ISSUE ΔQ 곡선을 모델 입력이 될 소수의 통계값으로 요약할 수 있는가?



1 목적 · 왜 봤나

ΔQ 곡선(1,000포인트)을 그대로 넣기엔 셀이 36개뿐 → 곡선 차이를 담는 소수의 통계값을 찾는다

2 무엇을 했나

- **[통계값 피쳐 추출]** Var·Min·Mean·Skew·Kurt를 log10|·|로 계산
- **[장/단수명 비교]** 최단·최장 셀의 ΔQ 곡선 비교
- 배치별 Spearman ρ , 셀 구조별 직선 적합 잔차

3 결과 · 해석

- log Var: 전체 ρ **-0.89**, 배치별 -0.83 / -0.71 / -0.80
- Min -0.88, Mean -0.86 (전체). Skew·Kurt는 배치마다 부호·크기 불안정
- 기존 구조로 맞춘 직선이 newstructure 셀을 평균 $\times 0.94$ (-6%)로 설명





4 시사점 → 모델링

- 세 배치 모두에서 가장 강하고 일관돼 log Var ΔQ 를 핵심 피쳐로
- Min·Mean은 Var와 거의 같은 정보(| ρ | 0.97~0.99)라 대체재로
- Skew·Kurt는 B1에서 상관이 우연 수준(신뢰 구간이 0 포함)이라 제외

“셀 구조가 달라도 같은 직선 위에 놓인다 — 충전방식·구조 정보 없이 측정 신호만으로 다른 배치에 일반화할 수 있다”

Q4 충전 조건(C-rate)과 수명의 관계

ISSUE 고속 충전 셀이 정말 수명이 짧은가? 충전 조건을 입력으로 쓸 수 있는가?



1 목적 · 왜 봤나

충전 조건이 수명을 설명한다면 바로 피처가 된다. 배치가 바뀌어도 같은 관계가 유지되는지 확인한다

2 무엇을 했나

- **[고속 충전 셀]** 충전방식 문자열 파싱 → 1·2단계 C-rate, 전환 SOC, 평균 C-rate, 0~80% 충전 시간 계산
- 전체 vs 배치 내 Spearman 비교
- 같은 충전방식 안에서 셀 구조별 수명 비교

3 결과 · 해석

- 모든 충전방식의 0~80% 충전 $\approx$ 10분 → 충전시간 자체는 변별력 없음
- 전체 상관 거의 없음($c1 \rho 0.08$, 평균 C-rate -0.25), 배치 내 $-0.78 / -0.18 / -0.52$
- 같은 충전방식(B2): 기존 구조 448~484 vs newstructure 872~991 (약 2배)



4 시사점 → 모델링

- 배치마다 쓴 충전방식이 달라(B1·B2 공통 2개) C-rate를 입력으로 쓰면 다른 배치에서 통하지 않아 제외
- newstructure는 B1에 한 건도 없어 학습할 수 없음
- 같은 충전방식끼리 학습·검증에 나뉘면 누수라 같은 충전방식끼리 묶어 fold 분할

“고속 충전 = 단명”은 같은 셀 구조 안에서만 성립한다 — 수명 차이는 충전방식보다 셀 구조에서 2배로 벌어진다”

Q4 충전방식별 평균 수명 · 전류 패턴과 열화 속도

ISSUE 충전방식별로 수명이 얼마나 다르고, 전류가 열화 “속도”를 바꾸는가?



1 목적 · 왜 봤나

충전방식 단위로 수명 차이를 보고, 전류 크기가 열화 속도(knee 전·후)에 미치는 영향을 정량화한다

2 무엇을 했나

- [충전방식별 평균 수명] 배치×충전방식 40그룹 평균 ± 표준편차
- [전류 패턴-열화 속도] 평균 C-rate vs knee 전·후 열화 속도 Spearman

3 결과 · 해석

- 하위 3개는 모두 B2 기존 구조(395 · 400 · 421), 최상위는 B3 4.8C(80%)-4.8C* 1,564
- 같은 4.8C(80%)-4.8C: 484 → 753 → 872 → 1,564 (3.2 배)
- C-rate-열화 속도 ρ : knee 전 0.77 / -0.11 / 0.41, knee 후 0.68 / 0.19 / 0.39



4 시사점 → 모델링

- 같은 충전방식 이름도 배치마다 수명이 달라 입력으로는 제외
- 전류가 열화에 준 영향은 실제로 측정된 ΔQ 에 이미 반영되므로 그걸로 대신함

“ B1 안에서는 전류가 클수록 열화가 빠르지만, 같은 C-rate에서도 열화 속도가 3~19로 퍼진다 — 충전방식만으로는 수명을 맞출 수 없다 ”

Q5 상관관계: 수명과 연관된 신호

ISSUE 초기 신호 중 무엇이 수명과 일관되게 연결되고, 무엇이 중복되는가?



1 목적 · 왜 봤나

후보 피처가 수명과 관련 있는지, 배치가 바뀌어도 유지되는지, 서로 겹치는지 확인해 피처 선정 기준을 세운다

2 무엇을 했나

- **[상관 계수]** 초기 100 cycle 피처 14개 vs log 수명, 전체 + 배치별 Spearman
- **[가장 강한 관계]** 상관 순위와 배치 간 일관성
- **[멀티콜리니어리티]** VIF, $|\rho| \geq 0.9$ 쌍

3 결과 · 해석




- ΔQ: Var -0.89, Min -0.88, Mean -0.86 (배치별 -0.66~-0.83)
- QD(2) -0.57, IR -0.45, T avg +0.31 등은 배치 내 $|\rho| \leq 0.37$ 로 약해지고 부호가 바뀐
- VIF: ΔQ Min 83 · Mean 46 · Var 24, T avg 46

4 시사점 → 모델링

- ΔQ 통계끼리 겹쳐서(VIF 83) 대표 1개(log Var)만 쓰고 나머지는 대체재로
- IR·온도는 학습 배치(B1)에서도 유의하지 않아 제외
- 테스트 Target이 새지 않도록 선택은 B1 기준으로

“ 폴링 상관 대부분은 배치·셀 구조가 만든 겉보기 상관이다 — 모든 배치에서 일관된 신호는 ΔQ(V)뿐 ”

ISSUE 학습(B1)에서 배운 관계가 테스트(B2)·B3에서도 통하는가? 분류로 풀 수 있는가?



	B1 학습	B2 테스트	B3 추가
사용 셀	36	39	44
수명 범위	534~1,074	392~1,186	541~1,935
newstructure 셀	0	9	44
550 이상 : 미만	35 : 1	9 : 30	43 : 1
다수결 정확도	97%	77%	98%

3 결과 · 해석

- 예비 baseline(log Var 단일 피쳐, B1 학습) MAPE: B1 8.2%(학습) · **B2 28.6%** · B3 12.8% (원논문 목표 9.1%)
- B2는 500~650 근처에서 막혀 과대예측(학습 하한 밖), B3 장수명(>1,500)은 과소예측
- B1의 550 미만 셀은 B1c20(534) 1개뿐. 전처리로 줄여든 게 아님 — 제외한 B1 10셀은 기록된 수명이 모두 879 이상이고, 46셀 전체로 봐도 550 미만은 1개


4 시사점 → 모델링

- 550 기준 분류는 B1에 단수명 셀이 1개뿐이라 학습·검증이 안 되고, B2는 찍기만 해도 77%라 **회귀를 선택**
- B2 성능은 학습 범위 밖을 얼마나 잘 이어서 예측하느냐에 달려 있어, 외삽 능력을 모델 선택 기준으로 삼음

“ 학습 범위 밖을 맞혀야 하는 문제다 — 학습 정확도보다 “범위 밖으로 외삽할 수 있는가”가 모델 선택 기준 ”

설계 ① Feature Engineering: 22개 후보 → 핵심 1 + 보조 3

ISSUE EDA에서 발견한 내용으로 유의미한 변수를 어떻게 선별했는가?



단계	어떻게 걸렀나
S1 사용 가능성	knee는 수명이 끝나야 알 수 있는 값이라(Q2), 첫 100 cycle 안에서 계산되는 값만 후보로 남김 → 22개
S2 측정값 vs 설계 조건	충전방식 변수 5개는 셀 상태를 켜 값이 아니고 배치마다 충전방식이 달라(B1·B2 공유 2개) 제외. newstructure는 B1에 한 건도 없어 학습 자체가 불가. 다만 평균 C-rate는 B1에서 $\rho -0.78$ 로 강하지만 충전방식 변수라 입력에서는 제외
S3 관련성	B1에서 bootstrap 2,000회로 상관계수의 95% 신뢰구간을 구해, 0을 포함하면(= 우연일 수 있으면) 제외 → Skew, Kurt, IR, 온도, QC, QD(2) 등 10개 탈락
S4 중복 제거	서로 $ \rho \geq 0.9$ 로 겹치는 쌍은 수명과 더 강한 쪽만 남김 → Min·Mean은 Var와 거의 같아(0.99·0.97) 대체재로 돌림
S5 배치 간 부호	B2/B3에서 방향이 뒤집히는 QD 기울기·충전시간은 빼지 않고 “보조(경고)”로만 표시

핵심 피쳐

log Var ΔQ

보조 피쳐

QD(cycle 100) · QD 기울기* · 충전시간*

* 배치마다 방향이 바뀌어 경고

대체재

log |Min ΔQ | · log |Mean ΔQ |

Var와 거의 같은 정보

넣고 빼는 판정은 학습 배치(B1)로만 해서 테스트 Target이 선택에 새지 않게 함

“ 셀 36개로 많은 피쳐를 쓰면 과적합된다 — 모든 배치에서 일관된 핵심 신호(ΔQ 분산)에 집중 ”

설계 ② Regression vs Classification · Target · 데이터 처리

ISSUE 하나의 방법만 선택한다면 무엇이고, Target은 무엇인가?

결정	무엇으로	왜
Regression vs Classification (택1)	Regression (초기 100 cycle → 총 수명)	550 cycle 기준으로 나누면 B1이 35:1이라 분류기를 학습시킬 수 없고, B2는 전부 “단수명”이라고만 해도 정확도 77%가 나와 분류 성능이 의미가 없어 회귀로 선택
Target	Target Data = cycle_life (EOL 80% SOH, 0.88Ah까지의 사이클 수) 모델은 $y = \log_{10}(\text{cycle_life})$ 를 예측	원논문과 같은 Target이라 목표 성능(MAPE 9.1%)과 직접 비교할 수 있음. 수명이 오른쪽으로 길게 치우쳐 있어(왜도 1.04) 로그로 퍼면 0.03으로 대칭이 되고, log Var ΔQ 와도 직선 관계가 돼 로그 수명을 예측. 평가(MAPE)는 다시 사이클 수로 되돌려 계산
데이터 처리	EOL 미도달 Target 값 없는 셀 제외 → cycle 1 더미 제거 → 용량 스파이크 보간 → $\Delta Q(V) = \text{cycle } 100 - 10 \rightarrow$ 스케일러는 학습 fold에서만 fit	EOL 미도달 셀은 Target 값이 실제보다 짧게 적혀 있어 제외. 이 중 시원하고 오래 사는 5셀이 온도 상관을 -0.48까지 끌어당겼지만 정상 36셀에서는 -0.17이라, 소수 셀에 결과가 휘돌리지 않게 함. 스파이크는 지우면 사이클이 비어서 주변 값으로 보간
피쳐 (X값)	초기 100 cycle 데이터로 계산한 피쳐만 사용 핵심 $\log \text{Var } \Delta Q(\text{cycle } 100 - 10) \cdot$ 보조 $QD(\text{cycle } 100)$, QD 기울기($\text{cycle } 2 \sim 100$), 충전시간($\text{cycle } 2 \sim 100$) · 대체재 $\log \text{Min } \Delta Q $, $\log \text{Mean } \Delta Q $	도메인 정보에서 “초기 100사이클만으로 전체 수명 예측 가능”이라고 하니 100사이클로 예측 시도. 그 안에서 세 배치 모두 수명과 일관되게 움직인 건 ΔQ 분산뿐($B1 \rho -0.83$, 신뢰구간 $-0.92 \sim -0.66$)이라 핵심으로, 나머지는 B1에서만 유의해 보조로 사용

피쳐 세트(ablation): $M1 = \{\log \text{Var}\} \cdot M2 = M1 + \text{보조 } 3\text{개}(\text{선택 결과}) \cdot M3 = M1 + M2 + \text{대체재}(\log |\text{Min } \Delta Q| \cdot \log |\text{Mean } \Delta Q|)$

검증 설계 (Notion Performance Reporting 형식)

- **Train** = Batch 1 CV 평균. 같은 충전방식끼리 학습·검증에 나뉘면 검증 셀의 Target을 미리 보는 셈이라 같은 충전방식끼리 묶어 fold를 나눔(GroupKFold)
- **Valid** = Batch 1에서 같은 충전방식끼리 묶어 약 20%를 떼어 둔 hold-out · **Test** = Batch 2 (마지막에 한번만), 추가로 Batch 3
- Gap(Train-Valid)으로 과적합, Gap(Valid-Test)로 배치 간 일반화, Gap(Target-Test)로 원논문 9.1% 대비 차이를 봄

예상 위험과 대응

- B2는 대부분 학습 범위보다 수명이 짧아 외삽이 필요하므로, 직선으로 이어지는 로그 선형 계열을 우선 사용
- newstructure 셀이 B1에 없어 B2 오차를 기존 구조 / newstructure로 나눠 보고, ΔQ 가 구조와 무관한지 잔차로 다시 확인
- 학습 셀이 36개뿐이라 튜닝은 Batch 1 안에서만 하고 Test는 건드리지 않음

“ Target Data = cycle_life = EOL(80% SOH)까지의 사이클 = ESS 배터리 교체 시점. 100 cycle 데이터로 교체 시점을 미리 예측한다 ”

설계 ③ Modeling Strategy: 데이터 특성 기반 후보 모델

ISSUE 확인한 데이터 특성에서 어떤 모델링 전략과 후보 모델이 나오는가?

확인한 데이터 특성	근거	모델링 전략 → 채택한 후보 모델
학습 셀이 36개뿐	B1 36셀	단순·정규화 모델 우선, 딥러닝 제외 → ① OLS, ② Elastic Net
B1에 단수명 셀이 1개뿐	B1의 550 미만은 1셀, B2는 39셀 중 30셀이 B1보다 짧음	짧은 수명도 직선으로 이어 예측하는 선형 모델 주력 → ② Elastic Net, ③ PLS (트리는 비교군으로만)
핵심 피처와 수명이 직선 관계	B1 ρ -0.83, 곡선을 넣어도 개선 없음	직선 모델로 충분 → ① OLS 기준선, ④ SVR/GPR로 재확인
피처끼리 정보가 겹침	ΔQ 통계끼리 상관 0.92~0.98	규제 또는 묶기 → ② Elastic Net(규제), ③ PLS(묶기)
배치마다 방향이 바뀌는 피처	충전시간, QD 기울기	보조로만 쓰고 조합 효과 확인 → ⑤ RF/GBM (비교군)
같은 충전방식끼리 수명이 비슷	충전방식 하나에 1~2셀씩 실험	같은 충전방식끼리 묶어 검증 데이터 분할 → 모든 모델에 적용
구조가 다른 셀이 섞임	B2 newstructure 9셀, B1엔 없음	B2 오차를 구조별로 나눠 보고 → 모든 모델에 적용

후보 모델 (모두 회귀)	역할	이유
① OLS (log Var ΔQ 1개)	기준선	원논문 방식. 다른 모델이 이걸 넘는지 비교
② Elastic Net	주력	셀이 적고 피처가 겹쳐 규제가 필요하고, 짧은 수명도 직선으로 예측 가능
③ PLS	주력	겹치는 피처를 몇 개 요인으로 묶어 사용 (대체재까지 넣은 피처 세트 M3)
④ SVR / GPR	확인용	곡선 모델로 “직선이면 충분한지” 재확인
⑤ RF / GBM	비교군	피처 조합 효과 확인. 학습에 없던 짧은 수명엔 약할 것으로 예상

“ 셀은 적고, 단수명은 학습에 거의 없고, 관계는 직선 → 정규화 선형 모델이 주력 ”

결론 EDA 확인 사항과 설계 결정

ISSUE 처음에 세운 가설은 어떻게 판정됐고, 그 결과 무엇을 결정했는가?

가설 검증 결과		
가설	판정	근거
H1 형태 신호	채택 — 초기 용량은 수명과 무관하게 겹치지만 log Var ΔQ 는 전 배치에서 $p \sim -0.71 \sim -0.83$, 셀 구조가 달라도 같은 직선	Q2, Q3
H2 충전 전류	부분 채택 — B1 안에서는 평균 C-rate $\uparrow \rightarrow$ 수명 $\downarrow$ ($p \sim -0.78$), 열화 속도 $\uparrow$. 전체로는 상관 없음, 셀 구조 효과(2배)가 더 큼	Q4
H3 저항·발열	기각 — IR·온도는 B1 상관의 95% CI가 0을 포함, 폴링 상관은 배치 효과	Q5

핵심 결론	
1. 배치마다 수명 분포가 다르다	— 평균 B1 788 · B2 566 · B3 1,060
2. 열화는 비선형	— 수명의 77%(knee) 이후 약 10배 가속. 초기 100 cycle의 용량은 거의 변하지 않음
3. 초기 신호는 $\Delta Q(V)$ 에 있다	— log Var ΔQ 와 log 수명 $p \sim -0.89$
4. 충전방식보다 셀 구조가 수명을 가른다	— 같은 충전방식에서 구조에 따라 2배
5. 소수의 잘린 셀이 상관을 왜곡한다	— 잘린 5셀 포함 시 온도 상관 -0.48 , 정상 셀만 보면 -0.17 . 수명 상위·하위 10셀의 온도 차는 0.5°C 뿐

설계 결정	내용
Regression vs Classification · Target	Target Data는 cycle_life. B1이 35:1로 치우쳐 분류는 학습이 안 되므로 회귀로, 수명 분포가 치우쳐 있어 log10(cycle_life)를 예측
피처	모든 배치에서 일관된 log Var ΔQ 를 핵심으로, B1에서만 유의한 QD(cycle 100)·QD 기울기·충전시간을 보조로 쓰고 M1-M3 비교로 확인
모델	36셀 소표본에 테스트가 학습 범위 밖이고 B1에서 직선 관계가 충분해, 외삽이 되는 정규화 선형 모델(Elastic Net·PLS)을 주력으로, OLS는 기준선, SVR/GPR·RF/GBM은 확인·비교용으로
검증	같은 충전방식끼리 나뉘지 않도록 B1을 묶어서 CV·hold-out하고, Test B2(+B3)는 마지막에 한 번만 평가해 Gap 3종을 보고

“ $\Delta Q(V)$ 하나로 셀 구조가 다른 배치까지 일반화한다 — DAY 2에서 Batch 2 외삽 성능으로 검증 ”