

ESS 배터리 수명 예측

모델 개발 및 평가 보고서

DAY 1 설계서(DS-MINI-Design) 기반 · 학습 Batch 1 → 테스트 Batch 2 (+ Batch 3)

진행 방식

1

설계 → 구현 점검

DAY 1 설계서 항목을 하나씩 구현하고 일치 여부 확인

2

데이터 분할 · 파이프라인

같은 충전방식끼리 묶어 CV · hold-out, 전처리하는 학습 fold 안에서만

3

후보 모델 학습 · 선택

후보 7개 × 피쳐 세트 M1·M2·M3 튜닝, Valid로 최종 조합 선택

4

성능 리포팅

Notion 형식(Train · Valid · Test · Gap)으로 Batch 2·3 평가

5

Gap 해석 · 도메인 해석

원논문 분할 재현, 오류 분석, ESS 운영 관점 해석과 한계

구성 설계 점검 (p.2) · 분할·파이프라인 (p.3) · 하이퍼파라미터 (p.4) · 평가지표 (p.5) · 모델 비교 (p.6) · 피쳐 세트 비교 (p.7) · 모델 선형성 (p.8) · 최종 성능 (p.9) · 과적합 점검 (p.10) · Gap 해석 ① (p.11) · 오류 분석 (p.12) · Gap 해석 ② (p.13) · 모델 선택 종합 (p.14) · ESS 해석·한계 (p.15) · 결론 (p.16)

설계서 항목	설계 내용	구현	일치
문제 · Target	Regression, $y = \log_{10}(\text{cycle_life})$	$\log_{10}$ 수명을 학습, 평가는 사이클 수로 되돌려 MAPE	✓
데이터 처리	EOL 미도달·Target 값 없는 셀 제외, 스파이크 보간, 스케일러·결측 대체는 학습 fold에서만	119셀 사용(B1 36 · B2 39 · B3 44). 결측 대체(중앙값)·스케일러를 모델과 한 파이프라인으로 묶어 fold 안에서만 학습	✓
피처	선정 피처 M2 = 핵심 1($\log \text{Var } \Delta Q$) + 보조 3(QD(cycle 100) · QD 기울기 · 충전시간)	후보 7개를 M1 · M2 · M3으로 모두 학습해 비교 → B1 검증 1위 조합이 M2 → 최종 M2	✓
피처 세트(ablation)	$M1 \cdot M2 \cdot M3 = M1 + M2 + \text{대체재}$	M1-M3 모두 후보 7개 전체로 학습해 비교	✓
후보 모델	① OLS(M1 기준선) ② Elastic Net ③ PLS ④ SVR/GPR ⑤ RF/GBM	후보 7개 × M1·M2·M3 = 21개 실행 (OLS도 다른 모델처럼 M1·M2·M3으로 학습, OLS(M1)이 설계서의 기준선)	✓
검증	Train = B1 CV(같은 충전방식끼리), Valid = B1 hold-out 약 20%, Test = B2 1회 + B3	GroupKFold 5-fold, hold-out 7셀(19%, 충전방식 4개), B1 전체 재학습 후 B2·B3 평가	✓
최종 모델 선택	Valid 성능으로 선택, Test는 선택에 사용 안 함	Valid 1위 SVR(M2) 선택. hold-out 20회 반복에서도 1위로 확인 (왜 이 모델인지는 뒤 “Gap 해석 ③”에서 평가 방식별로 종합 설명)	✓
모델 역할	Elastic Net · PLS 주력, SVR 확인용	선택 규칙대로 하니 확인용이던 SVR이 Valid 1위로 최종 선택	△ 예상과 다름
B2 구조별 보고	B2에는 셀 구조가 다른 두 집단이 섞임(기존 구조 30 셀 · newstructure 9셀, B1에는 newstructure 없음) → 두 집단의 오차를 나눠서 보고	B2 MAPE 기존 구조 31.7% · newstructure 30.5% → 구조와 상관없이 비슷하게 틀림	✓

△ 1건(모델 역할)은 결과에 그대로 밝힘. 나머지 항목은 설계서와 동일하게 구현

데이터 분할

- **Batch 1 (36셀)** → 같은 충전방식끼리 묶어 학습 29셀(충전방식 16개) / hold-out 7셀(충전방식 4개, 19%)
- hold-out 셀 수명: 599, 616, 636, 651, 702, 870, 1014
- **Train 성능** = 학습 29셀에서 GroupKFold 5-fold CV 평균 (튜닝도 여기서)
- **Valid 성능** = 튜닝된 설정으로 학습 29셀 학습 → hold-out 7셀 평가
- **Test** = 같은 설정으로 B1 36셀 전체 재학습 → Batch 2(39셀) 1회, Batch 3(44셀) 추가

누수를 막은 방법

- 같은 충전방식 셀은 항상 학습·검증 한쪽에만 → 검증 셀의 Target을 미리 보지 않음
- 전처리 기준값(중앙값·평균·표준편차)도 학습 데이터에서만 계산
- 튜닝·선택은 Batch 1 안에서만, Batch 2·3은 마지막 평가에만 사용

학습 파이프라인 (셀 1개 = 데이터 1행)

- ① 입력: 초기 100 cycle로 계산한 피쳐 — 후보 모델은 M1·M2·M3(최종 M2) · Target: $\log_{10}(\text{cycle_life})$
- ② 결측 대체: 학습 데이터 중앙값 (M1~M3 피쳐에는 결측이 없어 안전장치로 포함)
- ③ 표준화: 학습 데이터 평균·표준편차
- ④ 모델 학습 → 예측값을 $10^{\hat{y}}$ 로 되돌려 사이클 수로 평가
- ②~④를 하나의 파이프라인으로 묶어, fold마다 학습 데이터로만 다시 맞춤

재현

- `DAY2_modeling.ipynb` 한 번 실행으로 21개 실행 튜닝 · 평가 · 결과 저장
- 결과: `results/model_comparison.csv`, `results/model_performance.csv`
- 난수 고정(SEED = 0)

ISSUE 하이퍼파라미터를 어떻게 정했는가?

모델	탐색 범위	조합 수	선택값 (모델별 Valid 최상 피쳐 세트)
OLS	없음	—	— (M2)
ElasticNet	$\alpha 10^{-4} \sim 10^{-0.5}$ (12개) $\times$ l1_ratio {0.1, 0.5, 0.9, 1}	48	$\alpha=0.0001$, l1_ratio=0.1 (M1)
PLS	n_components {1, 2, 3}	3	n_components=1 (M1)
SVR	$C \{1, 10, 100\} \times \gamma \{0.01, 0.1, 1\} \times \epsilon \{0.01, 0.03\}$	18	$C=10$, $\gamma=0.01$, $\epsilon=0.01$ (M2)
GPR	커널 상수 $\times$ RBF+노이즈, 값은 최대우도로 자동 추정	—	— (M3)
RF	max_depth {2, 3, 없음} $\times$ min_samples_leaf {1, 3}, 트리 300개	6	max_depth=3, min_samples_leaf=1 (M3)
GBM	n_estimators {100, 300} $\times$ learning_rate {0.03, 0.1} $\times$ max_depth {2, 3}	8	n_estimators=100, learning_rate=0.03, max_depth=3 (M2)

탐색 방법

- 모델마다 격자 탐색(grid search), 학습 29셀 GroupKFold 5-fold CV MAPE가 가장 낮은 값 선택
- 셀이 29개라 탐색 범위를 작게 잡아 과적합 방지 (SVR 18개, Elastic Net 48개)

최종 모델 SVR(M2) 설정의 의미

- $C = 10$: 오차를 적당히 허용 (너무 크면 학습 셀에 과적합)
- $\gamma = 0.01$: RBF 폭이 넓어 거의 직선에 가까운 완만한 곡선 $\rightarrow$ 설계서의 “직선 관계” 결과와 일치
- $\epsilon = 0.01$: log 수명 기준 ± 0.01 (약 $\pm 2.3\%$) 안의 오차는 무시

ISSUE 무엇으로 성능을 재고, Gap은 어떻게 읽는가?

MAPE (Notion 지정 지표)

- $MAPE = \text{평균}(|\text{예측 수명} - \text{실제 수명}| \div \text{실제 수명}) \times 100$
- 모델은 $\log_{10}$ 수명을 예측하므로 $10^{\hat{y}}$ 로 사이클 수로 되돌린 뒤 계산
- “평균적으로 실제 수명의 몇 %만큼 틀렸나”라서 수명 400과 1,900 셀을 같은 기준으로 비교 가능
- 원논문도 같은 지표 → 목표 9.1%와 직접 비교

보조 지표

- RMSE(사이클 수): Batch 2 200 cycle · Batch 3 245 cycle
- 평균 부호 오차(+: 길게 예측) → 예측이 어느 방향으로 치우치는지 확인 (오류 분석에 사용)

Gap 읽는 법


- Gap = 뒤 단계 MAPE – 앞 단계 MAPE. (+)면 뒤 단계에서 더 틀림
- Gap(Train–Valid) (+) → 과적합 의심
- Gap(Valid–Test) (+) → 배치 간 일반화 저하 의심
- Gap(Target–Test) (+) → 원논문 9.1%보다 나쁨

선택 지표의 안정성 확인

- Valid가 7셀이라 우연에 흔들릴 수 있어, B1 안에서 같은 충전방식끼리 묶은 hold-out을 20회 반복
- SVR(M2) $6.90 \pm 1.54\%$ 로 반복에서도 1위 → 선택이 우연이 아님 (Batch 2·3 정보는 사용하지 않음)

모델 비교 후보 모델 비교와 최종 선택

ISSUE 후보 7개를 M1·M2·M3으로 모두 학습해 모델별 최상 조합끼리 비교하면, 무엇이 가장 좋은가?



조합 (모델별 Valid 최상 피쳐 세트)	Train CV	Valid	Valid 20회 반복	Test B2	Test B3
SVR (M2)	8.19	4.71	6.90 ± 1.54	31.45	12.45
GBM (M2)	10.69	5.65	8.77 ± 2.91	35.10	21.33
OLS (M2)	8.64	6.00	7.05 ± 1.30	39.35	12.97
GPR (M3)	10.34	6.30	8.01 ± 1.83	41.03	17.24
RF (M3)	10.22	6.33	9.47 ± 2.69	33.85	18.46
PLS (M1)	9.31	7.80	10.39 ± 2.36	28.56	12.81
ElasticNet (M1)	9.31	7.80	10.39 ± 2.36	28.56	12.81
OLS (M1 기준선)	9.31	7.80	10.39 ± 2.36	28.56	12.81


“ 모델별 최상 조합끼리 비교해도 SVR(M2)가 Valid 4.71%로 1위, 반복 hold-out(6.90%)에서도 1위. Elastic Net · PLS는 최상이 M1(피쳐 1개)이라 OLS(M1)과 같은 직선 — Valid 7.80% ”

왜 이 모델을 최종으로 선택했는지는 뒤의 “Gap 해석 ③”에서 평가 방식(Notion 방식 · 원논문 분할 방식)별로 모든 후보를 비교해 설명합니다.

피쳐 세트 비교: M1 · M2 · M3 → 최종 M2

ISSUE

어떤 피쳐 세트를 최종으로 골랐고, 왜인가?





SVR 기준 피쳐 세트	Train CV	Valid	Valid 20회 반복	Test B2	Test B3
M1 핵심 1개	9.62	8.73	10.40 ± 2.08	30.55	11.93
M2 핵심 + 보조 3개 (최종)	8.19	4.71	6.90 ± 1.54	31.45	12.45
M3 핵심 + 보조 + 대체재 (6개)	8.27	7.12	7.62 ± 1.63	45.00	19.13

선택 근거 (B1 검증만 사용)

- SVR 기준 Valid 4.71%(M2) < 7.12%(M3) < 8.73%(M1), 반복 hold-out도 M2가 가장 낮음 → 최종 피쳐 M2. 전체 21조합 중에서도 SVR(M2)가 Valid 1위
- M3는 M2에 대체재(log |Min ΔQ| · log |Mean ΔQ|)를 더한 6개. 대체재는 핵심과 상관이 0.97~0.99라 새 정보 없이 피쳐만 늘어 36셀 소표본에 부담 → B1 검증도 M2보다 나쁨
- M1은 B1 검증에서 가장 나쁨 → 보조 피쳐가 B1 안에서는 도움이 됨

참고: 테스트 결과 (선택에는 사용 안 함)

- SVR 기준 Batch 2는 M1 30.6% ≈ M2 31.5%, Batch 3도 M1 11.9% ≈ M2 12.5%로 비슷 → 보조 피쳐가 새 배치에서는 이득이 없음(설계서 “경고”와 일치)
- M3(피쳐 6개)는 새 배치에서 Batch 2 45.0% · Batch 3 19.1%로 가장 나쁨 → 겹치는 피쳐를 더할수록 B1에만 맞춰짐



모델 유형 분류

- **선형**: OLS · Elastic Net · PLS — 피처의 가중합(직선식)으로 예측
- **거의 선형**: SVR — RBF 커널을 쓰는 비선형 모델이지만 $\gamma = 0.01$ 로 매우 작아 완만한 곡선
- **비선형**: GPR · RF · GBM — 곡선·계단 형태의 관계도 학습

최종 SVR은 얼마나 직선에 가까운가

- SVR 예측을 같은 피처의 직선식으로 근사하면 **95% 설명**(119셀), B1만 보면 98%
- 119셀 중 113셀은 직선 예측과 10% 이내(중앙값 3.0%). 벗어나는 6셀은 피처가 극단인 셀(노이즈 셀 B3c37 등)
- 설계서의 직선 관계 확인과 일치: B1에서 $\log \text{Var } \Delta Q - \log \text{수명}$ 을 2차 곡선으로 바꿔도 R^2 0.712 → 0.719로 거의 그대로

선형 vs 비선형 성능 (피쳐 M2)

- B1 검증(20회 반복): 선형 7.0~8.3% / 비선형 6.9~8.8% → SVR이 가장 좋음
- Test B2: 선형 39~56% / 비선형 31~41%
- OLS도 M1(기준선, 피쳐 1개)에서는 B1 검증 10.4% · Test B2 28.6% · Test B3 12.8%

“ 설계서는 선형 모델을 주력으로 예상했지만, 직선에 약간의 곡률을 허용한 SVR이 B1 검증에서 가장 좋았다 — 이득은 B1 안에서 약 1.4%p이고, 처음 보는 배치(Batch 2)에서는 선형 OLS(M1) 28.6%가 SVR 31.5%보다 낮아 일관되지 않다 ”

ISSUE 최종 모델 SVR(M2)의 성능은?

구분	MAPE (%)	비고
Train (Batch 1 CV)	8.19	같은 충전방식끼리 묶은 5-fold CV 평균
Valid (Batch 1 Hold-out)	4.71	B1 7셀(충전방식 4개) hold-out
Test (Batch 2)	31.45	B1 전체 재학습 후 1회 평가
Gap (Train-Valid)	-3.48	(+) : 과적합 의심
Gap (Valid-Test)	+26.74	(+) : 배치간 일반화 저하 의심
Gap (Target-Test)	+22.35	Target : 원논문 9.1%
Test (Batch 3)	12.45	B3c37(노이즈 셀) 제외 시 12.32
Gap (Batch2-Batch3)	+19.00	Test 성능 간 비교
Gap (Target-Test B3)	+3.35	Batch 3 기준, 원논문 성능 비교

3 결과



- B1 안: Train 8.19% · Valid 4.71% → 과적합 없음(Gap -3.48)
- Batch 2: 31.45% → 배치 간 일반화 저하(Gap +26.74), 원논문 대비 +22.35%p
- Batch 3: 12.45% → 원논문 대비 +3.35%p, B3c37(노이즈 셀) 제외해도 12.32%
- Batch 2 구조별: 기존 구조 31.7% · newstructure 30.5% → 구조와 무관하게 비슷

4 해석 요약

- B1 안에서는 원논문 수준, 처음 보는 배치(Batch 2)에서 오차가 커짐
- 왜 SVR을 선택했는지는 뒤의 “Gap 해석 ③”에서 설명, B1에 과적합된 것인지는 다음 장에서 점검하고, Gap(Target-Test)의 원인은 Gap 해석 ①·②에서 분석: 회귀 선택 효과 · 원논문과의 분할 방식 차이

과적합 점검 B1만 학습한 모델의 과적합 점검

ISSUE B1만 학습해서 Batch 2에서 틀리는 것은 B1에 과적합됐기 때문인가?





점검 항목	결과	판단
① 학습 · 교차검증 · hold-out 오차	학습 셀 5.1% · 교차검증 8.2% · hold-out 4.7% (20회 반복 6.9 ± 1.5%)	학습 오차가 낮지만 검증 오차가 크게 벌어지지 않음 → 과적합 아 님
② 학습 곡선	학습 셀 8개 → 28개로 늘리면 학습·검증 오차 간격 8.0%p → 2.9%p, 검증 오차 10.8% → 7.5%	셀이 늘수록 두 오차가 가까워짐 → 소표본 과적합은 약하고, 셀이 더 있으면 더 좋아질 여지
③ 규제 강도 변경 (C)	규제를 세게(C=0.3) 걸면 Batch 2 47.4%로 오히려 나빠짐. 약하게(C=100) 하면 Batch 2 19.2%로 좋아지지만 Batch 3 20.7% · B1 교차검증 10.4%로 나빠짐	과적합이면 규제를 세게 걸수록 좋아져야 함 → 반대. Batch 2를 보고 C를 고르면 테스트 정보를 쓰는 것이라 선택값(C=10) 유지
④ 가장 단순한 모델	파라미터 2개짜리 직선(OLS, 피쳐 1개): B1 8.2% · Batch 2 28.6% · Batch 3 12.8%	복잡도를 최소로 줄여도 Batch 2 오차가 비슷 → 모델 복잡도 문 제가 아님
⑤ Batch 2 오차의 방향	예측이 평균 +30.5% 길게 치우치고, 셀의 92%가 실제보다 길게 예측. 그래도 순위는 유지 (Spearman 0.89)	무작위로 흩어지는 과적합이 아니라 한 방향으로 치우친 배치 간 이동

“ 과적합이 아니라 배치 이동이다 — B1 안에서는 일반화가 잘 되고, Batch 2에서는 대부분의 셀(92%)이 한쪽(길게)으로 치우치며 순위는 맞게 따라간다 ”

Gap 해석 ① Gap 해석 ①: 회귀를 선택한 효과와 오차가 생기는 구간

ISSUE Batch 2 오차는 회귀라서 생긴 한계인가?



Batch 2를 550 cycle 기준으로 장/단수명 판정	정확도	단수명 30셀 중 맞힘
분류 (B1이 장수명 35 : 단수명 10이라 사실상 “전부 장수명”만 학습)	23%	0셀
회귀 (SVR 예측값을 550으로 나눔)	41%	7셀

결과

- B1 수명 범위(534~1,074) 안의 셀은 Batch 2·3여도 MAPE 13.4%, 치우침 +3.5%로 거의 정확
- B1보다 짧은 셀(30셀, 전부 Batch 2)은 +31% 길게, 긴 셀(18셀)은 -20% 짧게 예측

해석

- 회귀를 선택해 분류보다 나아짐(정확도 23% → 41%). B2가 B1보다 짧다는 방향은 잡음
- 과적합 점검(앞 장)에서 B1 안의 과적합은 확인되지 않음
- 오차는 B1에 없던 수명 구간에서 발생 → 회귀의 한계가 아니라 **B1에 단수명 셀이 1개뿐인 학습 데이터의 한계**

ISSUE 모델이 가장 크게 틀린 셀은 어떤 셀이고, 왜 틀렸는가?

Batch 2 (길게 예측)

셀	충전방식 (*=newstructure)	실제	예측	오차
B2c9	5.6C(26%)-4.5C*	791	1,341	+70%
B2c44	5.2C(58%)-4C*	841	1,358	+62%
B2c6	3.6C(9%)-5C	393	593	+51%
B2c0	5.2C(58%)-4C	477	693	+45%

Batch 3 (짧게 예측)

셀	충전방식 (*=newstructure)	실제	예측	오차
B3c38	5C(67%)-4C*	1,935	1,067	-45%
B3c7	4.8C(80%)-4.8C*	1,836	1,186	-35%
B3c42	4.8C(80%)-4.8C*	1,642	1,071	-35%
B3c45	4.8C(80%)-4.8C*	1,801	1,249	-31%

3 공통점


- Batch 2: 92% 셀을 길게 예측(평균 +30.5%). 가장 짧은 기존 구조 셀(393~514)과 ΔQ 분산이 낮은 newstructure 셀
- Batch 3: 수명 1,600 이상 장수명 셀(4.8C(80%)-4.8C*)을 1,000~1,250으로 짧게 예측
- 두 경우 모두 **B1 학습 범위 밖의 셀**: 수명이 범위(534~1,074) 밖(B2c6 · B2c0 · B3 장수명 셀 전부)이거나, 수명은 범위 안(B2c9 791 · B2c44 841)이어도 log Var ΔQ (-4.34 · -4.36)가 B1 범위(-4.18~-3.35) 밖

4 원인 가설 · 개선 방향

- 같은 ΔQ 값이어도 배치마다 수명 수준이 다름(배치 차이) + 곡선형 SVR은 범위 밖에서 예측이 학습 범위 쪽으로 끌려옴
- 개선: 새 배치 셀 일부를 학습에 포함(혼합 분할에서 약 10% 확인), 학습 수명 범위 확대(EOL 미도달로 제외된 B1 장수명 셀의 수명 복원), 배치 차이를 보정하는 피쳐 탐색

Gap 해석 ② Gap 해석 ②: 원논문 분할 방식 재현

ISSUE 원논문 9.1%는 어떤 조건의 결과이고, 같은 방식으로 분할하면 우리 모델은?



평가 방식 (SVR M2)	학습	테스트	MAPE
Batch 2 · Notion 방식 (B1 학습 → B2 테스트)	B1 36셀	B2 39셀	31.45%
Batch 2 · 원논문 분할 방식 (B1+B2 혼합)	37셀 (B1 18 + B2 19)	38셀 (B1 18 + B2 20)	9.98%
Batch 3 · Notion 방식 (B1 학습 → B3 테스트)	B1 36셀	B3 44셀	12.45%
Batch 3 · 원논문 분할 방식 (B1+B3 혼합)	39셀 (B1 18 + B3 21)	41셀 (B1 18 + B3 23)	9.48%

우리 전처리 후 데이터(B1 36 · B2 39 · B3 44셀)를 원논문 방식(번갈아 분할)으로 나눔. 하이퍼파라미터는 Notion 방식(B1)에서 정한 값 그대로. 원논문 목표 9.1%

원논문 코드의 학습/테스트 분할 (LoadData.m 97~104행)

<https://github.com/rdbraatz/data-driven-prediction-of-battery-cycle-life-before-capacity-degradation/blob/master/LoadData.m#L97-L104>

```
test_ind = [1:2:(numBat1+numBat2), 84];
train_ind = 1:(numBat1+numBat2);
train_ind(test_ind) = [];
secondary_test_ind = numBat-numBat3+1:numBat;
```


- 대상: numBat1 + numBat2 = Batch 1(41셀) + Batch 2(43셀) = 84셀을 한 줄로 이어 붙인 목록 (66행 batch_combined = [batch1, batch2, batch3])
- test_ind = 번갈아 한 칸씩(1, 3, 5, ... + 84번째) → 테스트 43셀 / train_ind = 나머지 → 학습 41셀
- Batch 1과 Batch 2 셀이 학습·테스트에 절반씩 섞임

해석

- 같은 방식으로 분할하면 SVR(M2)이 Batch 2 10.0% · Batch 3 9.5% → 원논문 9.1% 수준
- Batch 2는 같은 모델 · 같은 피처인데 분할만 바뀌 31% → 약 10%, Batch 3도 12.5% → 9.5%
- Notion 과제는 B1만 학습 → 다른 배치 테스트로 처음 보는 배치를 맞춰야 해 더 어려움 (특히 B2)
- 다른 배치 셀을 학습에 넣으면 그 셀의 오차도 줄어듦 (B2 셀 9.3% · B3 셀 11.8%)

Gap 해석 ③ Gap 해석 ③: 평가 방식별 모델 비교와 최종 선택

ISSUE 평가 방식을 바꿔 모든 후보 모델을 비교하면, 왜 SVR을 최종으로 선택했는가?



모델 (피쳐 세트)	B1 검증 (20회 반복)	Notion Test B2	Notion Test B3	원논문 분할 B1+B2	원논문 분할 B1+B3	1위 횟수
OLS (M1) 기준선	10.39	28.56	12.81	14.41	10.95	1/5
OLS (M2)	7.05	39.35	12.97	11.86	9.20	1/5
ElasticNet (M2)	8.32	44.12	13.45	11.95	10.50	0/5
PLS (M2)	8.20	56.11	21.01	12.11	11.60	0/5
SVR (M2)	6.90	31.45	12.45	9.98	9.48	3/5
GPR (M2)	7.61	40.79	15.04	15.05	9.80	0/5
RF (M2)	8.83	34.23	18.26	11.12	11.00	0/5
GBM (M2)	8.77	35.10	21.33	10.76	10.14	0/5

그래서 SVR(M2)을 선택

- 5개 평가 중 3개에서 1위, 나머지도 2위(순위 1 · 2 · 1 · 1 · 2). 1위: B1 검증, Notion Test B3, 원논문 분할 B1+B2
- OLS가 1위인 곳: OLS(M1)은 Notion Test B2(28.6% vs SVR 31.5%), OLS(M2)는 원논문 분할 B1+B3(9.2% vs SVR 9.5%)
- OLS(M2)는 B1 검증도 7.05%로 SVR 6.90%에 근접 → 피쳐가 같으면 직선 모델과 SVR 차이는 크지 않음. 5개 평가 모두 상위권이고 B1 검증 1위라 SVR 선택

OLS(M1)가 Notion Test B2에서만 좋은 이유 · 선택 원칙

- OLS(M1)는 피쳐 1개(핵심)짜리라, 처음 보는 배치(B2)에서 보조 피쳐의 배치 간 방향 변화에 흔들리지 않음. 같은 OLS도 보조 피쳐를 넣으면(M2) B2에서 39.4%로 나빠짐. 다른 배치 셀을 학습에 넣으면 M1의 이점이 사라짐
- 최종 모델은 Test 결과를 보기 전에 정한 규칙(B1 Valid 1위)으로 선택. 테스트에서 가장 낮은 모델로 바꾸면 테스트 정보를 쓰는 것
- 차이가 1~3%p 수준이라 셀 수가 적어 흔들릴 수 있음

ISSUE 이 모델을 실제 BESS에 적용한다면 무엇에 쓰고, 무엇이 더 필요한가?

활용 가능한 의사결정

- 같은 생산 로트·운영 조건 안에서는 100 cycle 데이터로 수명을 약 5~12% 오차로 예측 → 셀·모듈별 교체 시점을 미리 계획
- 조기 선별: ΔQ 분산이 큰 셀을 100 cycle 시점에 단수명 후보로 분류해 집중 관리
- 예측이 길게 치우치는 경향(Batch 2) → 교체 계획에는 예측 수명에서 안전 마진을 빼서 사용

실 배포를 위해 필요한 것

- 새 로트·새 운영 조건마다 일부 셀을 knee 이후까지 측정해 재학습 (배치를 섞으면 약 10% 확인)
- 배치·로트 정보와 셀 구조 정보 관리 (newstructure처럼 구조가 바뀌면 수명이 2배 차이)
- 실제 ESS 운전 패턴(부분 충방전, 휴지, 온도 변화) 데이터로 재검증

개발 한계점

- 학습 셀 36개, 그중 단수명(<550) 1셀 → 짧은 수명 구간을 배울 데이터 부족
- Valid hold-out 7셀이라 성능 추정이 흔들릴 수 있음 (반복 hold-out으로 보완). 하이퍼파라미터도 같은 B1 교차검증으로 골라 B1 성능은 약간 낙관적일 수 있음
- Notion의 Batch 2 파일(2018-02-20)은 원본 저장소에서 Figure 4용 저속 측정 데이터로 분류된 보조 실험이라 원논문 수치와 조건이 다름
- 온도·IR은 측정 신뢰도와 배치별 측정 조건 차이로 사용하지 못함 (원본 데이터 설명)

다음 단계

- Batch 2 셀 일부를 학습에 넣는 운영 시나리오별 성능 곡선 (몇 셀을 넣으면 몇 %까지 줄어드는지)
- 배치 간 차이를 설명하는 피쳐 탐색 (충전 커브 시작점 등 Notion Batch 3 메모 항목)
- EOL 미도달로 제외한 B1 장수명 셀의 수명을 복원해 학습 수명 범위를 넓혀 장수명 예측 개선

결론: 설계 구현 결과와 Gap의 원인

ISSUE 설계서대로 구현한 결과, 무엇을 확인했는가?

구현 결과

1. **설계서대로 구현** — 9개 항목 중 8개 일치, 1개는 차이를 밝힘(확인용이던 SVR이 최종 모델로 선택됨)
2. **최종 모델 SVR(M2)** — Valid 4.71%, 반복 hold-out $6.90 \pm 1.54\%$ 로 1위
3. **성능** — Batch 2 31.45% · Batch 3 12.45% (원논문 9.1%)
4. **피처 세트** — M1 · M2 · M3을 후보 7개로 모두 학습해 B1 검증 1위 조합인 M2를 최종 선택.

Gap(Target-Test)의 원인

1. **분할 방식** — 원논문은 Batch 1·2를 섞어 학습. 같은 분할이면 우리 SVR도 9.6~10.0%
2. **학습 데이터** — B1 안에서는 과적합이 없고(학습 곡선·규제·단순 모델 점검), B1에 단수명 셀이 1개뿐이라 짧은 수명 구간을 학습하지 못함 (회귀 선택으로 분류보다는 개선: 정확도 23% → 41%)
3. **배치 차이** — 같은 ΔQ 값이어도 Batch 2 셀이 더 일찍 수명을 다함

“같은 배치 안에서는 원논문 수준(약 10%)이지만, 처음 보는 배치에서는 31% — 실제 ESS 적용에는 새 로트 데이터로 재학습하는 운영이 필요하다”